



Politechnika
Wrocławska

Analiza danych ankietowych

Sprawozdanie II

Autorzy

Nikodem Drelak

Aleksandra Miedzińska

Wrocław, 27 maja 2026

Spis treści

1	Wstęp	3
2	Zadanie 1	4
2.1	Opis działania algorytmu	4
2.2	Wnioski z analizy	4
3	Zadanie 2	5
3.1	Opis działania algorytmu	5
3.2	Wnioski z analizy	6
4	Zadanie 3	6
4.1	Opis działania algorytmu	6
4.2	Wnioski z analizy	6
5	Zadanie 4	7
5.1	Opis działania algorytmu	7
5.2	Wyniki obliczeń	7
5.3	Weryfikacja hipotez oraz interpretacja	8
6	Zadanie 5	8
6.1	Opis działania algorytmu	8
6.2	Wnioski z analizy	9
7	Zadanie 6	10
7.1	Opis działania algorytmu	10
7.2	Wyniki testu i weryfikacja hipotezy	10
7.3	Interpretacja wykresu reszt (asocjacyjnego)	11
8	Zadanie 7	12
8.1	Opis działania algorytmu	12
8.2	Wnioski z analizy	12
9	Zadanie 8 - Miary epidemiologiczne i ocena ryzyka	13
9.1	Opis działania algorytmu i założenia metodyczne	13
9.2	Wyniki obliczeń	14
9.3	Interpretacja i wnioski (Odpowiedź na pytanie z polecenia)	14
10	Zadanie 9	14
10.1	Opis działania algorytmu	14
10.2	Wnioski z analizy	15

11 Zadanie 10	16
11.1 Opis działania algorytmu	16
11.2 Wyniki i interpretacja wizualna	16
11.3 Wyniki i interpretacja wizualna	16
12 Zadanie *1 (Dodatkowe)	17
12.1 Opis działania algorytmu	17
12.2 Wnioski z analizy	18
13 Zadanie *2 (Dodatkowe) - Zależność między RR a OR	18
13.1 Weryfikacja numeryczna (Symulacja)	18
13.2 Dowód analityczny	19
13.3 Interpretacja praktyczna	20
14 Zadanie *3	20
14.1 Podpunkt (a)	20
14.2 Podpunkt (b)	21
14.3 Weryfikacja numeryczna (Symulacja 3D)	21
14.4 Dowód analityczny związku AR z RR	22

1 Wstęp

Celem raportu jest prezentacja wyników analizy statystycznej przeprowadzonej na danych kategorycznych i porządkowych. Przesłane nam zadania z listy 2. skupiają się na weryfikacji hipotez dotyczących struktur populacji oraz badaniu współzależności między cechami jakościowymi.

Zakres merytoryczny raportu obejmuje:

- **Weryfikację zgodności rozkładów:** wykorzystanie testów dla rozkładów dwumianowych oraz wielomianowych (testy chi-kwadrat Pearsona oraz największej wiarygodności).
- **Analizę tablic dwudzielczych:** badanie niezależności zmiennych przy użyciu dokładnego testu Fishera, testu Freemana-Haltona oraz metod asymptotycznych.
- **Wyznaczanie miar siły związku:** interpretację ryzyka względnego, ilorazu szans oraz różnicy proporcji, a także analizę miar asocjacji dla danych porządkowych (tau Kendalla, Gamma).
- **Zaawansowane techniki wizualizacji i redukcji wymiarów:** implementację i interpretację analizy korespondencji oraz wizualizację reszt standaryzowanych.

Wszystkie obliczenia i symulacje przeprowadziliśmy za pomocą języka programowania Python, z wyjątkiem zadania 5, zrealizowanego w pakiecie R.

2 Zadanie 1

2.1 Opis działania algorytmu

Zaimplementowany algorytm służy do estymacji jednoczesnych przedziałów ufności dla wektora prawdopodobieństw w rozkładzie wielomianowym. Celem jest oszacowanie odsetka pracowników deklarujących poszczególne poziomy zadowolenia ze szkolenia w całej populacji. Aby zagwarantować, że wszystkie k przedziałów ufności pokrywa rzeczywiste wartości parametrów z łącznym prawdopodobieństwem $1 - \alpha$, zastosowano poprawkę Bonferroniego. Algorytm realizuje następujące kroki:

1. **Estymacja punktowa:** Dla każdej z $k = 5$ kategorii wyznaczono frakcję z próby (estymator największej wiarygodności) zgodnie ze wzorem $\hat{p}_i = \frac{n_i}{n}$, gdzie $n = 200$ to całkowita wielkość próby.
2. **Poprawka Bonferroniego:** Wyznaczono wartość krytyczną z rozkładu normalnego standardowego. Zamiast standardowego kwantyla rzędu $1 - \frac{\alpha}{2}$, wykorzystano kwantyl rzędu $1 - \frac{\alpha}{2k}$ w celu skompensowania problemu wielokrotnego testowania.
3. **Błąd standardowy:** Obliczono błąd standardowy (SE) dla każdej kategorii przybliżając wariancję z próby: $SE_i = \sqrt{\frac{\hat{p}_i(1-\hat{p}_i)}{n}}$.
4. **Przedziały ufności:** Obliczono margines błędu i wyznaczono dolne oraz górne granice przedziałów ufności $[\hat{p}_i - z \cdot SE_i, \hat{p}_i + z \cdot SE_i]$. Dodatkowo wprowadzono zabezpieczenie ograniczające uzyskane granice do teoretycznie poprawnego przedziału $[0, 1]$.

Tabela 1: Wyniki jednoczesnych przedziałów ufności z poprawką Bonferroniego.

Opinia	n_i	$\hat{p}$	Dolna granica (95%)	Górna granica (95%)
Bardzo niezadowoleni	14	0,070	0,0235	0,1165
Niezadowoleni	17	0,085	0,0342	0,1358
Nie ma zdania	40	0,200	0,1271	0,2729
Zadowoleni	100	0,500	0,4089	0,5911
Bardzo zadowoleni	29	0,145	0,0809	0,2091

2.2 Wnioski z analizy

Na podstawie 95-procentowych jednoczesnych przedziałów ufności przedstawionych w tabeli 1 możemy z dużą pewnością wnioskować o strukturze zadowolenia w całej populacji pracowników:

- Najliczniejszą grupę stanowią pracownicy „Zadowoleni” ($\hat{p} = 0.50$). Jesteśmy w 95% pewni, że w całej populacji odsetek ten mieści się w przedziale od $\approx 40.89\%$ do $\approx 59.11\%$. Stanowi to zdecydowaną większość ankietowanych.

- Łącznie nastroje pozytywne (odpowiedzi „Zadowoleni” i „Bardzo zadowoleni”) obejmują blisko 64.5% badanej próby. Dolne granice przedziałów ufności wskazują, że w najgorszym scenariuszu co najmniej połowa wszystkich pracowników pozytywnie ocenia dopasowanie szkoleń.
- Frakcja osób negatywnie oceniających szkolenia jest stosunkowo niewielka. Dla odpowiedzi „Niezadowoleni” estymator wynosi 0.085 (przedział 0.0342 – 0.1358), a dla „Bardzo niezadowoleni” 0.070 (przedział 0.0235 – 0.1165).
- Znaczna część ankietowanych (20%, przedział 12.71% – 27.29%) nie ma wyrobionego zdania na temat szkoleń.

Dzięki zastosowaniu poprawki Bonferroniego mamy 95-procentową ufność, że **wszystkie pięć** oszacowanych przedziałów jednocześnie pokrywa rzeczywiste prawdopodobieństwa populacyjne. Wyniki wskazują na generalny sukces przeprowadzonych szkoleń, przy zachowaniu marginesu na usprawnienia dedykowane grupie niezdecydowanej i niezadowolonej.

3 Zadanie 2

3.1 Opis działania algorytmu

Zaimplementowana przez nas funkcja `p_value_multinomial` służy do weryfikacji hipotezy zerowej $H_0 : p = p_0$ przeciwko hipotezie alternatywnej $H_1 : p \neq p_0$ dla rozkładu wielomianowego. Algorytm realizuje następujące kroki:

1. **Walidacja danych:** Sprawdzenie zgodności wymiarów wektora obserwacji x oraz wektora prawdopodobieństw p_0 .
2. **Wyznaczenie parametrów:** Obliczenie całkowitej liczebności próby $n = \sum x_i$, liczby kategorii k oraz liczby stopni swobody $df = k - 1$.
3. **Obliczenie liczebności oczekiwanych:** Wyznaczenie wektora $E = n \cdot p_0$, reprezentującego teoretyczną liczbę obserwacji w każdej kategorii przy założeniu prawdziwości H_0 .
4. **Statystyka Pearsona:** Obliczenie statystyki $\chi^2 = \sum \frac{(x_i - E_i)^2}{E_i}$ oraz odpowiadającej jej wartości p -value przy użyciu funkcji przeżycia rozkładu chi-kwadrat.
5. **Statystyka ilorazu wiarygodności (G-test):** Wyznaczenie statystyki $G = 2 \sum x_i \ln \left(\frac{x_i}{E_i} \right)$. W implementacji zastosowano maskowanie logiczne dla $x_i > 0$, aby uniknąć błędów numerycznych przy obliczaniu logarytmów dla zerowych liczebności.

3.2 Wnioski z analizy

Dla przykładowych danych wejściowych $x = [22, 28, 25, 25]$ oraz założonego rozkładu jednostajnego $p_0 = [0.25, 0.25, 0.25, 0.25]$, oba testy wygenerowały zbliżone wyniki:

- Statystyka Pearsona: ≈ 0.72 , p -value ≈ 0.868 .
- Statystyka G-test: ≈ 0.727 , p -value ≈ 0.867 .

Biorąc pod uwagę standardowy poziom istotności $\alpha = 0.05$, otrzymane wartości p -value są znacznie wyższe od progu odrzucenia ($p > \alpha$). Oznacza to, że **nie ma podstaw do odrzucenia hipotezy zerowej**. Zaobserwowane różnice między liczebnościami empirycznymi a oczekiwanymi są statystycznie nieistotne i mogą wynikać jedynie z losowości próby.

4 Zadanie 3

4.1 Opis działania algorytmu

Zaimplementowany skrypt służy do weryfikacji hipotezy zerowej H_0 , zakładającej, że rozkład odpowiedzi na badane pytanie w wybranej grupie pracowników (Dział Produktowy – PD) jest równomierny. Algorytm realizuje następujące kroki:

1. **Walidacja i filtracja danych:** Wczytanie ramki danych, zidentyfikowanie dostępnych działów (['IT', 'PD', 'MK', 'HR']) oraz wyodrębnienie obserwacji należących wyłącznie do Działu Produktowego (PD).
2. **Agregacja wyników:** Zliczenie wystąpień poszczególnych wariantów odpowiedzi (zakodowanych w skali od -2 do 2). Uzyskano wektor liczebności empirycznych: $x = [9, 10, 17, 51, 11]$. Sumaryczna wielkość badanej próby w tym dziale wynosi $n = 98$.
3. **Definicja parametrów testu:** Utworzenie wektora oczekiwanych prawdopodobieństw dla rozkładu jednostajnego. Przy pięciu możliwych wariantach odpowiedzi ($k = 5$), prawdopodobieństwo dla każdego z nich przy założeniu H_0 wynosi $p_i = 0.20$, co daje wektor $p_0 = [0.2, 0.2, 0.2, 0.2, 0.2]$.
4. **Weryfikacja statystyczna:** Przekazanie danych do funkcji testującej w celu wyliczenia statystyki χ^2 (Pearsona) oraz statystyki G (ilorazu wiarygodności) dla $df = 4$ stopni swobody.

4.2 Wnioski z analizy

Dla analizowanych danych z Działu Produktowego wektor obserwacji znacząco odbiegał od równomiernego rozłożenia (dominacja wariantu „1”, który uzyskał ponad połowę wszystkich głosów). Zastosowane testy wygenerowały następujące wyniki:

- **Test Chi-kwadrat Pearsona:** statystyka $\chi^2 \approx 64.86$, p -value $\approx 2.76 \times 10^{-13}$.

- **Test ilorazu wiarygodności (G-test):** statystyka $G \approx 52.53$, $p\text{-value} \approx 1.07 \times 10^{-10}$.

Biorąc pod uwagę standardowy poziom istotności $\alpha = 0.05$, otrzymane wartości $p\text{-value}$ są bliskie zeru, a zatem drastycznie mniejsze od progu odrzucenia ($p < \alpha$). Oznacza to, że z całą pewnością **odrzucaamy hipotezę zerową** na rzecz hipotezy alternatywnej.

Rozkład odpowiedzi w badanym dziale nie jest równomierny. Różnice między zaobserwowanymi zliczeniami a wartościami oczekiwanymi (wynoszącymi po 19.6 dla każdej kategorii) są zbyt duże, aby mogły wynikać z losowości próby. Pracownicy działu PD wykazują wyraźną tendencję do wyboru konkretnych odpowiedzi (w szczególności oceny „zgadzam się”), co świadczy o ukształtowanej i niesymetrycznej opinii tej grupy.

5 Zadanie 4

5.1 Opis działania algorytmu

W celu weryfikacji hipotezy o niezależności zmiennych kategoryzowanych PŁEĆ oraz CZY_KIER zastosowaliśmy dokładny test Fishera. Skrypt w języku Python realizuje zadanie w następujących krokach:

1. **Tablica kontyngencji:** Agregacja danych do dwuwymiarowej tablicy krzyżowej za pomocą funkcji `crosstab`, zestawiającej płeć respondentów z zajmowanym przez nich stanowiskiem.
2. **Test Fishera:** Wykorzystanie funkcji `fisher_exact` z biblioteki `scipy.stats`. Funkcja ta wyznacza dokładną wartość prawdopodobieństwa testowego ($p\text{-value}$) w oparciu o rozkład hipergeometryczny, a także wartość empirycznego ilorazu szans.
3. **Weryfikacja hipotezy:** Automatyczne porównanie uzyskanego $p\text{-value}$ z założonym w zadaniu poziomem istotności $\alpha = 0.05$.

5.2 Wyniki obliczeń

Tabela 2: Tablica krzyżowa dla płci i zajmowanego stanowiska.

Płeć	Szeregowy (Nie)	Kierownik (Tak)
Kobiety (K)	63	8
Mężczyźni (M)	110	19

Parametry testu Fishera:

- **Wartość statystyki:** 1,3602
- **$p\text{-value}$:** 0,6659

5.3 Weryfikacja hipotez oraz interpretacja

Obliczenia przedstawiono w tabeli 2. Ponieważ otrzymane prawdopodobieństwo testowe p -value $\approx 0,6659$ jest znacznie wyższe od narzuconego poziomu istotności $\alpha = 0,05$, **nie ma najmniejszych podstaw do odrzucenia hipotezy zerowej o niezależności zmiennych**. Oznacza to, że na poziomie istotności 0.05 zajmowanie stanowiska kierowniczego jest niezależne od płci pracownika.

„Czy możemy wnioskować, że prawdopodobieństwa (kobiety i mężczyźni na stanowisku kierowniczym) są równe?”

Nie, nie możemy wnioskować o równości tych prawdopodobieństw w populacji. W statystyce klasycznej brak podstaw do odrzucenia hipotezy zerowej nie jest równoznaczny z udowodnieniem jej prawdziwości. Z wysokiego p -value wynika jedynie to, że zaobserwowane różnice w próbie (8 kierowniczek do 19 kierowników) nie są wystarczająco duże, aby wykluczyć, że powstały w wyniku zwykłego przypadku (błędu losowego).

6 Zadanie 5

6.1 Opis działania algorytmu

Celem analizy była weryfikacja hipotez o niezależności (hipoteza zerowa H_0) wybranych par zmiennych kategorialnych. Do tego celu zastosowano dokładny test Fishera w uogólnieniu Freemana-Haltona. Algorytm zrealizowano w następujących krokach:

1. **Przygotowanie i transformacja danych:** Zmienną ciągłą WIEK zdyskretyzowano, tworząc nową zmienną kategorialną WIEK_KAT (4 przedziały wiekowe). Dodatkowo, na bazie oryginalnej, 5-stopniowej skali zadowolenia (PYT_2), wygenerowano dychotomiczną zmienną CZY_ZADOW („zadowolony” / „niezadowolony”), pomijając odpowiedzi neutralne.
2. **Tablice krzyżowe:** Dla każdej definiowanej pary zmiennych wygenerowano tablice kontyngencji, odfiltrując uprzednio braki danych (NA).
3. **Estymacja p -value (Monte Carlo):** Przeprowadzono test dokładny Fishera za pomocą funkcji `fisher.test` w języku R. Ze względu na złożoność obliczeniową dla tabel o wymiarach rzędu np. 5×4 , zastosowano aproksymację poziomu krytycznego p -value metodą symulacji Monte Carlo. Skrypt wykonał $B = 10000$ powtórzeń dla każdej pary zmiennych w celu zagwarantowania wysokiej precyzji wyniku.
4. **Weryfikacja hipotez:** Otrzymane wartości p -value przyrównano do przyjętego poziomu istotności $\alpha = 0.05$.

Tabela 3: Wyniki dokładnego testu Fishera w uogólnieniu Freemana-Haltona.

Badana para cech	p -value	Wniosek statystyczny
CZY_KIER vs WIEK_KAT	0,7841	Nie odrzucamy H_0
CZY_KIER vs STAŻ	0,0002	Odrzucamy H_0
PYT_2 vs CZY_KIER	0,0427	Odrzucamy H_0
PYT_2 vs STAŻ	0,0109	Odrzucamy H_0
PYT_2 vs PŁEĆ	0,4716	Nie odrzucamy H_0
PYT_2 vs WIEK_KAT	0,3168	Nie odrzucamy H_0
CZY_ZADOW vs CZY_KIER	0,8377	Nie odrzucamy H_0
CZY_ZADOW vs STAŻ	0,4001	Nie odrzucamy H_0
CZY_ZADOW vs PŁEĆ	0,6589	Nie odrzucamy H_0
CZY_ZADOW vs WIEK_KAT	0,3316	Nie odrzucamy H_0

6.2 Wnioski z analizy

Na podstawie wyników testu Freemana-Haltona (Tabela 3) można sformułować następujące wnioski o strukturze badanej populacji:

- **Zależności strukturalne (niezwiązane ze szkoleniami):** Wykazano bardzo silną zależność statystyczną między zajmowanym stanowiskiem (CZY_KIER) a stażem pracy (STAŻ) ($p = 0.0002$). Jest to zjawisko naturalne – awans na stanowisko kierownicze zazwyczaj wymaga określonego doświadczenia. Z kolei zajmowane stanowisko okazało się niezależne od kategorii wiekowej ($p = 0.7841$).
- **Czynniki wpływające na zadowolenie (oryginalna skala PYT_2):** Poziom zadowolenia ze szkoleń, mierzony w pełnej, 5-stopniowej skali, zależy istotnie statystycznie od zajmowanego stanowiska ($p = 0.0427$) oraz od stażu pracy ($p = 0.0109$). Oznacza to, że kadra kierownicza oraz osoby o określonym stażu oceniają dopasowanie szkoleń w zauważalnie inny sposób (np. są bardziej krytyczne lub przeciwnie – bardziej usatysfakcjonowane) niż reszta załogi. Zadowolenie jest natomiast niezależne od płci ($p = 0.4716$) oraz wieku ($p = 0.3168$).
- **Zjawisko utraty informacji przy dychotomizacji (CZY_ZADOW):** Najciekawszym wnioskiem płynącym z analizy jest całkowity brak istotności statystycznej ($p > 0.05$) dla wszystkich relacji badanych z użyciem zmiennej przekształconej CZY_ZADOW. Spłaszczenie 5-stopniowej skali do wariantu binarnego oraz odrzucenie wariantu neutralnego („0”) doprowadziło do zatarcia różnic między grupami. Świadczy to o tym, że zależność między zadowoleniem a stanowiskiem czy stażem pracy nie leży w prostej opozycji „zadowolony vs niezadowolony”, lecz ukryta jest w **intensywności** tych odczuć (np. różnicy między odpowiedziami „1” a „2”) lub w proporcji osób niezdecydowanych.

7 Zadanie 6

7.1 Opis działania algorytmu

W celu zweryfikowania hipotezy o niezależności stopnia zadowolenia ze szkoleń (PYT_2) od zajmowanego stanowiska (CZY_KIER), zastosowano klasyczny test niezależności χ^2 Pearsona. Implementacja w języku Python przebiegła według następującego schematu:

1. **Generowanie rozkładu empirycznego:** Przy użyciu funkcji `pandas.crosstab` utworzono dwuwymiarową tablicę kontyngencji dla badanych zmiennych.
2. **Test χ^2 :** Obliczenia przeprowadzono za pomocą funkcji `chi2_contingency` z biblioteki `scipy.stats`. Funkcja ta wyznacza statystykę testową, poziom krytyczny (p -value), liczbę stopni swobody oraz macierz teoretycznych liczebności oczekiwanych.
3. **Analiza reszt standaryzowanych:** Aby zidentyfikować kategorie generujące największe odchylenia od modelu niezależności, wyliczono macierz reszt standaryzowanych Pearsona według wzoru:

$$r_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}$$

gdzie O_{ij} to liczebność zaobserwowana, a E_{ij} oczekiwana.

4. **Wizualizacja (Wykres asocjacyjny):** Wyliczone reszty zaprezentowano na wykresie typu heatmapa (mapa ciepła) przy użyciu pakietu `seaborn`. Zastosowanie palety rozbieżnej (niebiesko-czerwonej) pozwoliło na intuicyjne zróżnicowanie komórek z nad-reprezentacją (wartości dodatnie) od tych z niedoreprezentacją (wartości ujemne).

7.2 Wyniki testu i weryfikacja hipotezy

Tabela 4: Wyniki testu niezależności χ^2 Pearsona dla zmiennych PYT_2 i CZY_KIER.

Parametr testu	Wartość
Statystyka χ^2	13,1137
Liczba stopni swobody (df)	3
Poziom krytyczny (p -value)	0,0044
Poziom istotności (α)	0,01

Wyniki działania algorytmów przedstawiono w tabelach 4 i 5. Algorytm wygenerował statystykę testową na poziomie $\chi^2 \approx 13.11$, co przełożyło się na wartość p -value ≈ 0.0044 .


Przyjmując narzucony w poleceniu rygorystyczny poziom istotności $\alpha = 0.01$, stwierdzamy, że p -value jest od niego mniejsze ($0.0044 < 0.01$). Wobec tego **odrzucaamy hipotezę zerową o niezależności zmiennych**. Oznacza to, że ocena dopasowania szkoleń jest statystycznie zależna od faktu zajmowania (lub nie) stanowiska kierowniczego.

Tabela 5: Reszty standaryzowane Pearsona dla poszczególnych kategorii.

Ocena (PYT_2)	CZY_KIER = Nie	CZY_KIER = Tak
-2	-0,0013	0,0032
-1	0,1683	-0,4260
1	-1,3153	3,3294
2	0,1097	-0,2776

Porównanie z zadaniem 5: Uzyskany wynik jest w pełni spójny z wnioskiem wyciągniętym w zadaniu 5 (gdzie stosowano test Freemana-Haltona dla $\alpha = 0.05$). Oba testy jednoznacznie potwierdzają istnienie istotnego powiązania między stanowiskiem a satysfakcją ze szkolenia. Zastosowanie surowszego progu istotności (0.01) w teście χ^2 utrzymało werdykt w mocy.

7.3 Interpretacja wykresu reszt (asocjacyjnego)



Rysunek 1: Wykres asocjacyjny reszt.

Przedstawiony na rysunku 1 wykres asocjacyjny precyzyjnie identyfikuje źródła odrzuconej niezależności. Kluczowe odchylenia od modelu teoretycznego koncentrują się wokół odpowiedzi numer "1" na skali zadowolenia:

- Dla grupy kierowników (CZY_KIER = Tak) i odpowiedzi "1" obserwujemy bardzo dużą, **dodatnią resztę standaryzowaną (3.33)**. Świadczy to o silnej nadreprezentacji — kierownicy wybierali tę odpowiedź znacznie częściej, niż zakładałby model zakładający brak związku.

- Symetrycznie, dla grupy pracowników szeregowych i tej samej odpowiedzi "1", obserwujemy wyraźną niedoreprezentację (ujemna reszta na poziomie -1.32).

Większość pozostałych komórek wykazuje reszty bliskie zeru, co sugeruje, że to właśnie specyficzna inklinacja kierowników do wyboru opcji "1" w głównej mierze zaważyła na statystycznym odrzuceniu niezależności w całym teście.

8 Zadanie 7

8.1 Opis działania algorytmu

Celem zaimplementowanego skryptu jest weryfikacja hipotezy o niezależności (H_0) dwóch zmiennych kategoryalnych (poziomu zadowolenia `PYT_2` oraz zajmowanego stanowiska `CZY_KIER`) przy użyciu testu opartego na ilorazie wiarygodności (tzw. G-test). Własna implementacja algorytmu realizuje następujące kroki:

1. **Agregacja danych:** Na podstawie ramki danych tworzona jest empiryczna tablica krzyżowa (kontyngencji) O zliczeń poszczególnych wariantów odpowiedzi.
2. **Wyznaczenie wartości oczekiwanych:** Dla każdej komórki wyliczana jest teoretyczna liczebność oczekiwana E , przy założeniu prawdziwości hipotezy o niezależności, korzystając z iloczynu odpowiednich sum brzegowych (wierszy i kolumn) podzielonego przez całkowitą liczbę obserwacji.
3. **Obliczenie statystyki G:** Statystyka testowa wyznaczana jest zgodnie ze wzorem:

$$G = 2 \sum_{i,j} O_{ij} \ln \left(\frac{O_{ij}}{E_{ij}} \right)$$

Aby zapobiec błędom numerycznym związanym z logarytmowaniem zera (co miałyby miejsce w komórce dla oceny „1” i braku stanowiska kierowniczego), zastosowano logiczne maskowanie tablicy, uwzględniając w sumowaniu wyłącznie komórki, w których $O_{ij} > 0$.

4. **Weryfikacja statystyczna:** Wyznaczono liczbę stopni swobody $df = (r - 1)(c - 1) = 3$. Następnie, wykorzystując funkcję przeżycia (survival function) rozkładu χ^2 , obliczono poziom krytyczny p -value dla wyznaczonej statystyki G .

8.2 Wnioski z analizy

Na podstawie przeprowadzonego testu ilorazu wiarygodności dla wygenerowanej tablicy krzyżowej (4×2) przedstawionej w tabeli 6 otrzymano następujące parametry:

- Statystyka G: ≈ 8.3285
- Liczba stopni swobody: $df = 3$

Tabela 6: Tablica krzyżowa zliczeń poszczególnych wariantów odpowiedzi z zadania 7.

PYT_2	Czy_kier	
	Nie	Tak
-2	64	10
-1	18	2
1	0	2
2	91	13

- Wartość p -value: ≈ 0.0397

Zakładając standardowy poziom istotności $\alpha = 0.05$, wyliczona wartość p -value jest od niego mniejsza ($p < \alpha$). W związku z tym **odrzucaamy hipotezę zerową** na rzecz hipotezy alternatywnej.

Zmienne PYT_2 (stopień zadowolenia w 5-stopniowej skali) oraz CZY_KIER (fakt zajmowania stanowiska kierowniczego) **są ze sobą zależne**. Potwierdza to wcześniej sformułowane wnioski, że perspektywa i ocena dopasowania szkoleń różnią się w sposób istotny statystycznie w zależności od miejsca pracownika w hierarchii firmy.

9 Zadanie 8 - Miary epidemiologiczne i ocena ryzyka

9.1 Opis działania algorytmu i założenia metodyczne

W celu oceny siły związku pomiędzy narażeniem na czynnik ryzyka (palenie papierosów) a wystąpieniem punktu końcowego (zgon z powodu raka płuc lub choroby niedokrwiennej serca), zaimplementowano skrypt obliczający trzy klasyczne miary epidemiologiczne. Oznaczając prawdopodobieństwo zgonu w grupie narażonej (palaczy) jako p_1 , a w grupie nienarażonej (niepalących) jako p_2 , wyznaczono:

1. **Różnicę proporcji (RD - Risk Difference):** $RD = p_1 - p_2$. Jest to miara bezwzględna, określająca nadmiarowe ryzyko w populacji przypisywane ekspozycji.
2. **Ryzyko względne (RR - Relative Risk):** $RR = \frac{p_1}{p_2}$. Jest to miara względna, wskazująca, ile razy większe jest prawdopodobieństwo zdarzenia w grupie narażonej względem grupy kontrolnej.
3. **Iloraz szans (OR - Odds Ratio):** $OR = \frac{p_1/(1-p_1)}{p_2/(1-p_2)}$. Stanowi on stosunek szansy wystąpienia zdarzenia w grupie badanej do szansy w grupie kontrolnej.

Obliczenia zostały zautomatyzowane przy użyciu biblioteki **pandas** w środowisku Python, co pozwoliło na jednoczesne przetworzenie danych dla obu badanych jednostek chorobowych i wygenerowanie zestawienia tabelarycznego.

9.2 Wyniki obliczeń

Zestawienie wyliczonych miar współzmienności dla obu chorób prezentuje Tabela 7.

Tabela 7: Zestawienie miar epidemiologicznych dla palenia papierosów.

Przyczyna zgonu	Różnica proporcji (RD)	Ryzyko względne (RR)	Iloraz szans (OR)
Rak płuc	0,00130	14,00000	14,01858
Choroba niedokrwienna serca	0,00256	1,61985	1,62402

9.3 Interpretacja i wnioski (Odpowiedź na pytanie z polecenia)

Na podstawie uzyskanych wyników możemy sformułować następujące interpretacje dla obu schorzeń:

- **Rak płuc:** Ryzyko zgonu na raka płuc jest u palaczy aż **14-krotnie wyższe** ($RR = 14.0$) w porównaniu do osób niepalących. Podobną wartość przyjmuje iloraz szans ($OR \approx 14.02$). W ujęciu bezwzględnym, na każde 100 000 osób, palenie odpowiada za 130 nadmiarowych zgonów rocznie ($RD = 0.00130$).
- **Choroba niedokrwienna serca:** Ryzyko zgonu na serce jest u palacza wyższe o około 62% ($RR \approx 1.62$) niż u osoby niepalącej. Szansa na taki zgon wzrasta w podobnym stopniu ($OR \approx 1.62$). Warto jednak zauważyć, że w ujęciu bezwzględnym palenie generuje tu aż 256 nadmiarowych zgonów rocznie na 100 000 osób ($RD = 0.00256$).

Związek której pary zmiennych jest silniejszy?

W statystyce medycznej i epidemiologii **siłę związku przyczynowo-skutkowego mierzy się za pomocą miar względnych** (RR oraz OR). Z tej perspektywy związek między paleniem a śmiercią na raka płuc jest **drastycznie silniejszy** ($RR = 14$) niż powiązanie palenia z chorobami serca ($RR \approx 1.62$).

Warto jednak dodać istotny komentarz epidemiologiczny: z racji tego, że choroby serca są znacznie bardziej powszechne (wyższe prawdopodobieństwo bazowe w populacji), to w wartościach bezwzględnych (RD) palenie "zabija" rocznie więcej osób na serce niż na raka płuc. Ryzyko względne (RR) mówi nam o biologicznej sile związku w etiologii choroby, podczas gdy różnica proporcji (RD) obrazuje skalę problemu dla zdrowia publicznego.

10 Zadanie 9

10.1 Opis działania algorytmu

Celem algorytmu było wyznaczenie miar współzmienności (korelacji) dedykowanych dla zmiennych porządkowych. Analizie poddano trzy relacje między zmiennymi: zadowoleniem

ze szkoleń (PYT_2, skala 5-stopniowa), stażem pracy (STAŻ, zmienna porządkowa) oraz faktem zajmowania stanowiska kierowniczego (CZY_KIER, przekształcona na binarną zmienną porządkową 0/1). Skrypt realizuje następujące kroki:

1. **Przygotowanie danych:** Utworzenie kopii roboczej ramki danych, zmapowanie wartości tekstowych („Nie”/„Tak”) na wartości numeryczne (0/1) w celu narzucenia relacji porządku oraz usunięcie braków danych dla badanych kolumn.
2. **Współczynnik Gamma Goodmana-Kruskala (γ):** Zaimplementowano funkcję obliczającą statystykę opartą na parach obserwacji. Na bazie tablicy krzyżowej zliczana jest liczba par zgodnych (N_c , ang. *concordant*) oraz niezgodnych (N_d , ang. *discordant*). Wynik obliczany jest ze wzoru:

$$\gamma = \frac{N_c - N_d}{N_c + N_d}$$

3. **Współczynnik Tau-b Kendalla (τ_b):** Wykorzystano wbudowaną funkcję z pakietu `scipy.stats`. Miara ta, w przeciwieństwie do podstawowej wersji Tau-a, uwzględnia występowanie tzw. wiązań (ang. *ties*), co jest ważne w przypadku danych ankietowych, gdzie wiele osób wybiera te same warianty odpowiedzi. Funkcja zwraca również poziom krytyczny p -value dla testu istotności współczynnika korelacji.

10.2 Wnioski z analizy

Na podstawie uzyskanych współczynników τ_b oraz γ (przy poziomie istotności $\alpha = 0.05$) można sformułować następujące wnioski:

- **Stanowisko vs Staż pracy:** Zidentyfikowano istotną statystycznie ($p = 0.0000$), dodatnią korelację. Szczególnie wyraźnie widać to we współczynniku Gamma ($\gamma \approx 0.7527$), który jest bardzo wrażliwy na zgodność kierunku zmian. Oznacza to silną tendencję: im dłuższy staż pracy pracownika, tym większe prawdopodobieństwo, że zajmuje on stanowisko kierownicze.
- **Zadowolenie vs Staż pracy:** Brak istotnej korelacji ($p = 0.4672$). Wartości współczynników są bardzo bliskie zeru ($\tau_b \approx 0.0481$, $\gamma \approx 0.0908$). Czas spędzony w firmie nie wpływa kierunkowo na ocenę szkoleń.
- **Zadowolenie vs Stanowisko:** Brak istotnej korelacji rzędów ($p = 0.8486$). Otrzymane współczynniki ($\tau_b \approx -0.0130$, $\gamma \approx -0.0341$) sugerują brak związku monotonicznego.

Ważna uwaga analityczna: W poprzednich etapach analizy (testy niezależności Chi-kwadrat / G-test) wykazano, że zmienna PYT_2 jest w ogólnym ujęciu **zależna** od zajmowanego stanowiska. Obecny brak korelacji porządkowej nie przeczy tamtym wynikom. Oznacza to jedynie, że relacja ta nie jest monotoniczna (liniowa). Różnice między kierownikami a

pracownikami szeregowymi istnieją (np. częstsze wybieranie ocen skrajnych przez jedną z grup), ale nie przybierają postaci prostej reguły „im wyższe stanowisko, tym wyższa/nniższa ocena”.

11 Zadanie 10

11.1 Opis działania algorytmu

W celu wizualizacji relacji między stopniem zadowolenia (PYT_2) a stażem pracy (STAŻ), zaimplementowano funkcję analizy korespondencji. Algorytm realizuje następujące kroki matematyczne:

1. **Macierz korespondencji:** Przekształcenie tablicy kontyngencji X w macierz prawdopodobieństw $P = X/N$, gdzie N jest sumą wszystkich obserwacji.
2. **Masy profilowe:** Wyznaczenie wektorów mas wierszowych r i kolumnowych c (sumy brzegowe macierzy P).
3. **Standaryzacja reszt:** Obliczenie macierzy ustandaryzowanych reszt S według wzoru:

$$S = D_r^{-1/2}(P - rc^T)D_c^{-1/2}$$

gdzie D_r i D_c to macierze diagonalne mas.

4. **Dekompozycja SVD:** Rozkład macierzy S na wartości osobliwe ($S = U\Sigma V^T$) w celu znalezienia osi wyjaśniających największą część bezwładności (całkowitej zmienności).
5. **Współrzędne główne:** Wyznaczenie współrzędnych dla kategorii wierszy i kolumn w nowej, zredukowanej przestrzeni.


11.2 Wyniki i interpretacja wizualna

Wygenerowany biplot (Rysunek 2) pozwala na jednoczesną analizę obu zmiennych w przestrzeni dwuwymiarowej.

11.3 Wyniki i interpretacja wizualna

Interpretacja wyników:

- **Wysoka jakość modelu:** Dwa pierwsze wymiary wyjaśniają łącznie 100% całkowitej zmienności (86,71% oraz 13,29%), co wynika z liczby stopni swobody dla zmiennej „Staż” i gwarantuje absolutną wiarygodność prezentowanego wykresu.
- **Najwyższe niezadowolenie u nowych:** Pracownicy o najkrótszym stażu (**Staż 1**) najsilniej wiążą się z negatywną oceną szkoleń. Ich punkt na wykresie leży najbliżej kategorii „Bardzo niezad.” (**Opcja -2**).



Rysunek 2: Biplot analizy korespondencji dla zmiennych PYT_2 i STAŻ.

- **Najwyższe zadowolenie u „średniaków”:** Pracownicy ze średnim stażem (**Staż 2**) wykazują największy optymizm – na biplotcie ich pozycja niemal pokrywa się z deklaracją pełnej satysfakcji ze szkoleń („Bardzo zadow.” / **Opcja 2**).
- **Umiarkowana postawa doświadczonych:** Najbardziej doświadczeni pracownicy (**Staż 3**) są wyraźnie przesunięci na osi poziomej w prawą stronę, wykazując powiązanie z ogólną kategorią „Zadowoleni” (**Opcja 1**), która stanowi silny punkt odniesienia na wykresie.

Wniosek końcowy: Analiza wykazała nieliniowy wpływ stażu na ocenę szkoleń. Największy krytycyzm i niezadowolenie cechuje nowych pracowników (**Staż 1**), podczas gdy największy entuzjazm oraz wysoka satysfakcja występują w grupie o średnim stażu (**Staż 2**).

12 Zadanie *1 (Dodatkowe)

12.1 Opis działania algorytmu

Celem zaimplementowanego skryptu była weryfikacja hipotezy o niezależności zmiennych z wykorzystaniem korelacji odległości (ang. *Distance Correlation*, dCor). W przeciwieństwie do klasycznego współczynnika Pearsona, korelacja odległości równa zero wtedy i tylko wtedy, gdy zmienne są całkowicie niezależne, co pozwala na detekcję zależności nieliniowych. Algorytm zrealizowano w następujących krokach:

1. **Macierze odległości i podwójne centrowanie:** Dla wektorów X i Y wyznaczono macierze odległości euklidesowych. Następnie poddano je operacji podwójnego centrowania (odjęcie średnich wierszowych, kolumnowych oraz dodanie średniej ogólnej), uzyskując macierze A i B .
2. **Korelacja odległości:** Obliczono kowariancję odległości ($dCov^2$) oraz wariancję, a następnie wyznaczono ostateczną miarę $dCor$ ze wzoru:

$$dCor(X, Y) = \sqrt{\frac{dCov^2(X, Y)}{\sqrt{dCov^2(X)} \cdot dCov^2(Y)}}$$

3. **Test permutacyjny (weryfikacja H_0):** Ponieważ analityczny rozkład statystyki $dCor$ jest skomplikowany, poziom krytyczny p -value wyznaczono empirycznie za pomocą testu permutacyjnego. Wektor Y został losowo przetasowany $N = 1000$ razy. Wartość p -value obliczono jako proporcję permutacji, dla których uzyskano korelację odległości równą lub większą od korelacji zaobserwowanej dla oryginalnych danych (z doliczeniem 1 w liczniku i mianowniku, zgodnie ze sztuką testów randomizacyjnych).

12.2 Wnioski z analizy

Algorytm przetestowano na dwóch wygenerowanych scenariuszach ($n = 100$ obserwacji każdy), uzyskując następujące wyniki (przy $\alpha = 0.05$):

- **Scenariusz 1 (Zmienne całkowicie niezależne):** Dla dwóch niezależnych wektorów z rozkładu normalnego miara $dCor$ wyniosła 0.1903, a test permutacyjny zwrócił $p \approx 0.2507$. Ponieważ $p > \alpha$, nie ma podstaw do odrzucenia hipotezy zerowej. Algorytm poprawnie zidentyfikował brak zależności.
- **Scenariusz 2 (Zależność nieliniowa – parabola):** Wygenerowano wektor X z rozkładu jednostajnego, a wektor Y zdefiniowano jako $Y = X^2 + \varepsilon$ (gdzie ε to szum normalny). Tradycyjna korelacja liniowa Pearsona dla tych danych wyniosła $r \approx -0.1250$, fałszywie sugerując brak istotnego związku między zmiennymi. Tymczasem **korelacja odległości wyniosła 0.5061**, a test permutacyjny zwrócił $p \approx 0.0010$.

Odrzucenie hipotezy zerowej w drugim scenariuszu ($p < \alpha$) stanowi dowód na wysoką skuteczność korelacji odległości. Narzędzie to bezbłędnie wyłapało silną, nieliniową zależność (kształt paraboli), która pozostała całkowicie niewidoczna dla klasycznych metod badających wyłącznie relacje liniowe.

13 Zadanie *2 (Dodatkowe) - Zależność między RR a OR

13.1 Weryfikacja numeryczna (Symulacja)

Przed przystąpieniem do dowodu analitycznego, tezę zadania zweryfikowano eksperymentalnie przy użyciu autorskiego skryptu w języku Python.

W tym celu, za pomocą biblioteki `numpy`, wygenerowano dwuwymiarową siatkę (100×100) prawdopodobieństw π_1 oraz π_2 z przedziału $[0.01, 0.99]$. Dla każdej z 10 000 możliwych par prawdopodobieństw algorytm wyliczył wartość ryzyka względnego (RR) oraz ilorazu szans (OR), a następnie zbadał ich bezwzględną odległość od wartości 1 (która odpowiada całkowitej niezależności zmiennych).

Zaimplementowany warunek logiczny sprawdził, czy dla każdej iteracji zachodzi nierówność $|RR - 1| \leq |OR - 1|$. Algorytm **w 100% potwierdził badaną tezę**. Wybrane wartości z siatki symulacyjnej zaprezentowano w Tabeli 8.

Tabela 8: Przykładowe punkty z siatki symulacyjnej wygenerowane przez algorytm.

π_1	π_2	RR	OR	Odległość RR od 1	Odległość OR od 1
0,11	0,21	0,524	0,466	0,476	0,534
0,80	0,41	1,971	5,852	0,971	4,852
0,50	0,50	1,000	1,000	0,000	0,000

13.2 Dowód analityczny

Zakładamy, że prawdopodobieństwa π_1 (ryzyko w grupie badanej) oraz π_2 (ryzyko w grupie kontrolnej) przyjmują wartości z przedziału $(0, 1)$. Wychodzimy od podstawowej definicji obu miar. Ryzyko względne (RR) określamy wzorem:

$$RR = \frac{\pi_1}{\pi_2}$$

Iloraz szans (OR) definiujemy jako stosunek szans:

$$OR = \frac{\frac{\pi_1}{1-\pi_1}}{\frac{\pi_2}{1-\pi_2}} = \frac{\pi_1}{\pi_2} \cdot \frac{1-\pi_2}{1-\pi_1}$$

Zauważmy, że we wzorze na OR możemy wyodrębnić RR :

$$OR = RR \cdot \frac{1-\pi_2}{1-\pi_1}$$

Aby wykazać tezę, należy rozpatrzeć trzy możliwe relacje między π_1 a π_2 :

Przypadek 1: Dodatni związek badanych cech ($\pi_1 > \pi_2$)

Skoro $\pi_1 > \pi_2$, to z definicji otrzymujemy $RR > 1$. Z nierówności $\pi_1 > \pi_2$ wynika również, że $1 - \pi_1 < 1 - \pi_2$. Dzieląc obie strony przez dodatnie $(1 - \pi_1)$, otrzymujemy ułamek większy od jedności:

$$\frac{1 - \pi_2}{1 - \pi_1} > 1$$

Wracając do głównego równania, mnożymy RR przez ułamek większy od 1, co daje nam:

$$OR > RR > 1$$

Wartość RR znajduje się bliżej 1 niż wartość OR .

Przypadek 2: Ujemny związek badanych cech ($\pi_1 < \pi_2$)

Skoro $\pi_1 < \pi_2$, to z definicji $RR < 1$. Analogicznie, wynika z tego, że $1 - \pi_1 > 1 - \pi_2$. Dzieląc przez $(1 - \pi_1)$, otrzymujemy:

$$\frac{1 - \pi_2}{1 - \pi_1} < 1$$

Mnożąc RR przez liczbę mniejszą od 1, dodatkowo pomniejszamy jego wartość:

$$OR < RR < 1$$

Również w tym wariancie, wartość RR jest "wciśnięta" pomiędzy OR a 1.

Przypadek 3: Brak związku statystycznego ($\pi_1 = \pi_2$)

Jeśli ryzyka są równe, to z definicji $RR = 1$. Wtedy ułamek $\frac{1-\pi_2}{1-\pi_1}$ wynosi dokładnie 1. Wobec tego $OR = 1 \cdot 1 = 1$. Obie miary są równe i pokrywają się z jedynką.

Konkluzja dowodu: W każdym z możliwych scenariuszy wartość Ryzyka Względego (RR) znajduje się na osi liczbowej nie dalej od wartości 1 niż Iloraz Szans (OR), co można zapisać w postaci nierówności wartości bezwzględnych:

$$|RR - 1| \leq |OR - 1|$$

Co należało dowieść.

13.3 Interpretacja praktyczna

Powyższy dowód ma kluczowe znaczenie w statystyce medycznej, ponieważ tłumaczy zjawisko tzw. **przeszacowania ilorazu szans**. Miara OR ma matematyczną tendencję do "radikalizowania" efektu — jeśli badany czynnik zwiększa ryzyko, OR wskaże wynik jeszcze wyższy niż RR ; jeśli przed nim chroni, OR pokaże jeszcze silniejszą ochronę. Z tego względu OR nie powinno być bezpośrednio traktowane jako miara ryzyka dla chorób częstych w populacji, gdyż prowadzi to do sztucznego wyolbrzymiania wpływu badanych czynników.

14 Zadanie *3

14.1 Podpunkt (a)

Interpretacja miary AR

Wzór klasyczny na Populacyjne Ryzyko Przypisane zdefiniowany jest następująco:

$$AR = \frac{P(D) - P(D|E')}{P(D)}$$

Aby zrozumieć ten wskaźnik, należy przeanalizować jego elementy:

- $P(D)$ to całkowite prawdopodobieństwo (ryzyko) wystąpienia choroby w badanej populacji.
- $P(D|E')$ to ryzyko bazowe — częstość występowania choroby u osób **nienarażonych** na badany czynnik.
- **Licznik** $P(D) - P(D|E')$: Określa nadmiarowe ryzyko w populacji wynikające z obecności czynnika szkodliwego. Jest to ta część całkowitego ryzyka, która przewyższa naturalne ryzyko bazowe.
- **Mianownik** $P(D)$: Służy do normalizacji. Dzieląc nadmiar ryzyka przez całkowite ryzyko, otrzymujemy proporcję.

Ostateczna interpretacja: Miara AR (Attributable Risk Fraction) określa **odsetek wszystkich przypadków choroby w populacji, który można przypisać badanej ekspozycji**. Innymi słowy, wskazuje na to, jakiego odsetka zachorowań można by w teorii uniknąć, gdyby z populacji całkowicie wyeliminowano dany czynnik ryzyka (np. gdyby wszyscy przestali palić papierosy).

14.2 Podpunkt (b)

14.3 Weryfikacja numeryczna (Symulacja 3D)

Przed przystąpieniem do interpretacji i dowodu analitycznego, poprawność obu wzorów na wskaźnik Populacyjnego Ryzyka Przypisanego (AR) zweryfikowano numerycznie.

Wykorzystując bibliotekę `numpy` w języku Python, wygenerowano trójwymiarową siatkę miliona kombinacji dla parametrów: $P(E)$ (prewalencja ekspozycji), $P(D|E)$ (ryzyko w grupie narażonej) oraz $P(D|E')$ (ryzyko w grupie nienarażonej). Następnie dla każdej z kombinacji obliczono wartość całkowitego ryzyka $P(D)$ na mocy Prawa Całkowitego Prawdopodobieństwa oraz Ryzyko Względne (RR).

W końcowym etapie algorytm wyliczył wskaźnik AR dwiema niezależnymi metodami (wzorem klasycznym oraz przekształconym) i porównał je z dokładnością zmiennoprzecinkową. Wynik testu na milionie przypadków jednoznacznie **potwierdził identyczność obu wzorów**. Wybrane próbki z symulacji przedstawiono w Tabeli 9.

Tabela 9: Przykładowe punkty z siatki symulacyjnej wygenerowane przez algorytm.

$P(E)$	$P(D E)$	$P(D E')$	AR (definicja)	AR (nowy wzór)
0,51	0,11	0,21	-0,45783	-0,45783
0,81	0,51	0,41	0,16502	0,16502
0,31	0,91	0,71	0,08053	0,08053

14.4 Dowód analityczny związku AR z RR

Celem jest wykazanie tożsamości:

$$AR = \frac{P(E)(RR - 1)}{1 + P(E)(RR - 1)}$$

Wychodzimy z definicji Ryzyka Względnego (RR):

$$RR = \frac{P(D|E)}{P(D|E')} \implies P(D|E) = RR \cdot P(D|E')$$

Z Prawa Całkowitego Prawdopodobieństwa wiemy, że ogólne ryzyko $P(D)$ wynosi:

$$P(D) = P(E)P(D|E) + P(E')P(D|E')$$

Podstawiając $P(E') = 1 - P(E)$ oraz wyznaczone wyżej $P(D|E)$, otrzymujemy:

$$P(D) = P(E) \cdot [RR \cdot P(D|E')] + [1 - P(E)] \cdot P(D|E')$$

Wyciągamy wspólny czynnik $P(D|E')$ przed nawias i grupujemy wyrażenia z $P(E)$:

$$P(D) = P(D|E') \cdot [P(E) \cdot RR + 1 - P(E)]$$

$$P(D) = P(D|E') \cdot [1 + P(E)(RR - 1)]$$

Mamy już wyznaczony mianownik $P(D)$. Podstawiamy go do klasycznego wzoru na AR :

$$AR = \frac{P(D) - P(D|E')}{P(D)}$$

$$AR = \frac{P(D|E') \cdot [1 + P(E)(RR - 1)] - P(D|E')}{P(D|E') \cdot [1 + P(E)(RR - 1)]}$$

W liczniku ponownie wyciągamy $P(D|E')$ przed nawias:

$$AR = \frac{P(D|E') \cdot ([1 + P(E)(RR - 1)] - 1)}{P(D|E') \cdot [1 + P(E)(RR - 1)]}$$

Prawdopodobieństwo $P(D|E')$ skraca się w liczniku i mianowniku. Jednocześnie w nawiasie w liczniku odejmują się jedynki ($1 - 1 = 0$). Otrzymujemy postać końcową:

$$AR = \frac{P(E)(RR - 1)}{1 + P(E)(RR - 1)}$$

Co należało dowieść. Udowodniono tym samym, że wskaźnik AR można w pełni wyznaczyć znając jedynie prevalencję ekspozycji $P(E)$ oraz siłę jej związku z chorobą RR , bez konieczności szacowania ryzyk absolutnych w podgrupach.